La Convergence de l'Intelligence de Programmation : Analyse de la Parité entre les Modèles Chinois et la Lignée OpenAI Codex 5.4

Le secteur de l'intelligence artificielle en 2026 est marqué par une transition fondamentale des modèles de langage vers des systèmes agentiques capables non seulement de générer du texte, mais d'interagir avec des environnements informatiques complexes pour résoudre des problèmes d'ingénierie logicielle de bout en bout. Au centre de cette révolution, OpenAI a consolidé sa domination avec le lancement du GPT-5.4, un modèle qui a officiellement absorbé les capacités de la lignée spécialisée Codex pour devenir le premier modèle généraliste capable de surpasser les performances humaines dans l'utilisation de environnements de bureau.[1] Cependant, cette hégémonie est désormais contestée par une génération de modèles chinois d'une sophistication technique inédite. Les architectures développées par DeepSeek, Alibaba Cloud, Zhipu AI et Moonshot AI ne se contentent plus de suivre les traces de la lignée GPT-5.3 et 5.4 ; elles proposent des solutions architecturales distinctes pour résoudre les problèmes de latence, de coût d'inférence et de fidélité contextuelle sur de longues périodes.[4] Cette analyse examine en profondeur la parité technique de ces modèles par rapport aux standards fixés par OpenAI, en explorant les mécanismes de leur efficience et les implications de leur intégration dans les flux de travail professionnels.

Le Standard GPT-5.4 et l'Évolution de la Lignée Codex

Pour évaluer les alternatives chinoises, il est impératif de définir la position actuelle de la lignée OpenAI. Le lancement de GPT-5.4 en mars 2026 a marqué la fin de Codex en tant qu'entité séparée, fusionnant les capacités de programmation de pointe avec un modèle de raisonnement multimodal généraliste.[1] Ce modèle se distingue par sa capacité native d'utilisation de l'ordinateur, atteignant un taux de succès de 75,0 % sur le benchmark OSWorld-Verified, dépassant pour la première fois la ligne de base humaine fixée à 72,4 %.[1] Cette compétence permet au modèle de naviguer dans des environnements de bureau, de manipuler des fichiers et d'interagir avec des navigateurs de manière autonome, transformant l'IA d'un simple assistant de complétion de code en un ingénieur logiciel capable de gérer des tâches multi-étapes complexes.[1]

Sur le plan technique, GPT-5.4 intègre un mécanisme de recherche d'outils (Tool Search) qui réduit les coûts de tokens de 47 % dans les flux de travail agentiques lourds, en chargeant les définitions d'outils à la demande plutôt qu'en les injectant systématiquement dans le contexte.[1] Cette innovation est cruciale pour la gestion des fenêtres de contexte allant jusqu'à un million de tokens, spécifiquement disponibles via l'API et l'interface Codex.[1] Le modèle excelle

particulièrement sur le benchmark SWE-bench Pro, une variante plus rigoureuse et moins sensible à la contamination des données, où il affiche un score de 57,7 %, surpassant les 56,8 % du GPT-5.3-Codex.[2]

Tableau 1 : Performances de Référence de la Lignée OpenAI (Mars 2026)

Métrique / Benchmark	GPT-5.2	GPT-5.3 Codex	GPT-5.4
SWE-bench Pro (Public)	55,6 % [7]	56,8 % [7]	57,7 % [2]
OSWorld-Verified	47,3 % [2]	64,0 % [2]	75,0 % [1]
Terminal-Bench 2.0	62,2 % [6]	77,3 % [6]	75,1 % [6]
GDPval (Knowledge Work)	70,9 % [1]	Non testé [3]	83,0 % [1]
Fenêtre de Contexte (API)	Standard	400K [8]	1,0M [2]

La régression légère sur Terminal-Bench 2.0 par rapport au GPT-5.3 Codex suggère que l'unification du modèle a entraîné des ajustements dans la gestion des commandes CLI au profit d'une meilleure capacité d'interaction visuelle et de navigation.[6] Néanmoins, GPT-5.4 demeure le leader en matière de polyvalence, offrant une profondeur de raisonnement configurable qui permet d'ajuster l'effort de calcul selon la complexité de la tâche, une fonctionnalité qui définit désormais le standard du marché pour les systèmes de production.[4]

DeepSeek V4 : L'Architecture de l'Efficience Massive

Le défi le plus direct à la suprématie d'OpenAI provient de DeepSeek, dont la version V4 représente une percée majeure dans l'économie de l'IA. Lancé en février 2026, DeepSeek V4 repose sur une architecture Mixture-of-Experts (MoE) d'environ un trillion de paramètres, dont seulement 37 milliards sont activés par token.[4] Ce modèle a été conçu pour répondre aux contraintes matérielles imposées par les restrictions d'exportation de puces haut de gamme vers la Chine, forçant les ingénieurs à innover au niveau logiciel pour compenser les limites du matériel domestique comme les accélérateurs Huawei Ascend 910B.[11]

L'innovation centrale de DeepSeek V4 réside dans son architecture de mémoire conditionnelle Engram.[10] Contrairement aux transformeurs standards qui perdent en efficacité à mesure que le contexte s'allonge, Engram découple le stockage des motifs statiques du raisonnement dynamique, permettant une recherche de connaissances en temps constant ($O(1)$).[10] Ce mécanisme utilise le hachage multi-têtes pour mapper les contextes compressés vers des tables d'embeddings, évitant ainsi l'explosion de la consommation mémoire tout en maintenant une précision de 97,0 % sur les tests de type "Needle-in-a-Haystack" à l'échelle d'un million de tokens.[4]

Tableau 2 : Comparaison Technique DeepSeek V4 vs GPT-5.4

Caractéristique	DeepSeek V4	GPT-5.4
Architecture	MoE (1T total / 37B actifs) [10]	Unifiée (Propriétaire) [1]
Fenêtre de Contexte	1M Tokens (Natif) [4]	272K (Standard) / 1M (Codex) [2]
Précision Retrieval	97,0 % (Engram) [10]	79,3 % (à 256K tokens) [1]
Score HumanEval	90,0 % (Leaked) [11]	82,0 % [4]
Coût d'Inférence (1M tokens)	~$0,28 (Entrée) / $1,10 (Sortie) [4]	~$10,00 (Entrée) / $30,00 (Sortie) [4]
Architecture de Mémoire	Engram conditionnelle [10]	Transformer standard

L'impact de DeepSeek V4 sur le marché est avant tout économique. Avec un coût d'inférence environ 27 à 50 fois inférieur à celui du GPT-5.4 pour des tâches de codage comparables, il rend viable l'utilisation d'agents autonomes à grande échelle pour l'indexation de bases de code complètes ou la revue de code systématique en CI/CD.[4] Alors qu'une équipe traitant 10 millions de tokens par jour dépenserait environ 40 000 dollars par an avec GPT-5.4, le coût chute à environ 1 400 dollars avec DeepSeek V4.[4] Cette parité de performance, couplée à une disruption tarifaire, positionne DeepSeek comme l'alternative privilégiée pour les entreprises dont les budgets d'IA sont une contrainte majeure.

Les performances revendiquées sur SWE-bench Verified (80 %+) placent DeepSeek V4 au même niveau que les meilleurs modèles d'Anthropic et d'OpenAI, bien que ces chiffres restent à valider par des tiers indépendants.[4] La force de DeepSeek ne réside pas seulement dans sa taille, mais dans l'utilisation de techniques de prédiction multi-tokens et de connexions

hyper-contraintes (mHC) qui stabilisent l'entraînement à une échelle massive, permettant au modèle de maintenir une cohérence structurelle sur de très longues séquences de code.[10]

Alibaba Qwen3 : La Modularité et l'Apprentissage Agentique

Alibaba Cloud a adopté une stratégie différente avec sa série Qwen3, se concentrant sur l'optimisation des signaux d'entraînement agentiques plutôt que sur la simple augmentation de la taille des paramètres. Le modèle phare pour le codage, Qwen3-Coder-Next, est un modèle à poids ouverts de 80 milliards de paramètres qui n'active que 3 milliards de paramètres lors de l'inférence.[15] Malgré cette taille réduite, il atteint un score de 44,3 % sur SWE-bench Pro, rivalisant avec des modèles 10 à 20 fois plus grands en termes de paramètres actifs.[15]

L'approche de Qwen repose sur l'utilisation massive de synthèses de tâches exécutables et l'apprentissage par renforcement basé sur les retours d'environnements réels.[15] Au lieu de se contenter de prédire le token suivant, Qwen3-Coder-Next a été entraîné pour comprendre l'état d'un noyau (kernel), inspecter des variables et appeler des outils dans le bon ordre pour résoudre des problèmes complexes.[16] Cette spécialisation lui permet d'afficher des performances comparables à celles de Claude Sonnet 4.5 sur les benchmarks de codage, tout en étant déployable localement sur du matériel grand public haut de gamme.[15]

Tableau 3 : Gamme Qwen3 et Spécifications Agentiques (2026)

Modèle	Paramètres Actifs	Context Window	Points Forts
Qwen3-235B-A22B	22B [18]	256K - 1M [19]	Dual-mode (Thinking/Fast) [18]
Qwen3-Coder-Next	3B [15]	256K [15]	Entraînement agentique local [16]
Qwen3-32B	32B (Dense) [20]	131K (YaRN) [20]	Score HumanEval 88,0 [20]
Qwen3.5	Non spécifié	262K [21]	Alternative gratuite à Sonnet 4.6 [22]

L'une des fonctionnalités les plus appréciées des utilisateurs de Qwen3 est le mode de "réflexion hybride" (hybrid thinking mode), qui permet de basculer entre un raisonnement rapide et une analyse profonde sans changer de modèle.[18] Cette flexibilité reflète les niveaux d'effort de raisonnement du GPT-5.4, offrant aux développeurs un contrôle granulaire sur la

consommation de ressources selon que la tâche est une simple correction de syntaxe ou une refactorisation structurelle complexe.[19] En termes de vitesse, Qwen3.5 gagne du terrain sur la part de marché de Claude Sonnet, devenant le choix par défaut pour les projets secondaires et les flux de travail sensibles au coût, grâce à ses paliers d'API gratuits et sa qualité de code presque indistinguable des modèles payants sur 80 % des tâches courantes.[22]

Zhipu AI (Z.ai) et la Lignée GLM-5 : L'Ingénierie de Systèmes Complexes

Zhipu AI, issue des laboratoires de l'Université Tsinghua, s'est positionnée comme l'un des producteurs de modèles de fondation les plus actifs avec sa série GLM-5. Le modèle GLM-5, lancé en février 2026, est passé de 355 milliards de paramètres (GLM-4.5) à 744 milliards, avec 40 milliards de paramètres actifs.[23] Ce modèle se distingue par sa capacité à gérer des tâches de "long horizon", c'est-à-dire des processus de développement qui s'étendent sur plusieurs jours et nécessitent une maintenance constante de l'état du projet.[24]

La version spécialisée GLM-5.1 a démontré une résilience exceptionnelle lors de tests d'optimisation de bases de données vectorielles (VectorDBBench). Alors que les modèles standards ont tendance à plafonner après quelques dizaines de tentatives, GLM-5.1 a continué à trouver des améliorations significatives sur plus de 600 itérations et 6 000 appels d'outils, multipliant par six la performance initiale du code généré.[25] Cette capacité à itérer de manière autonome sans dérive instructionnelle le rapproche des performances agentiques du GPT-5.4 Thinking.[25]

Tableau 4 : GLM-5 vs Concurrents (Indice d'Intelligence et Programmation)

Métrique / Modèle	GLM-5	GPT-5.2 (xhigh)	Claude Opus 4.5
SWE-bench Verified	77,8 % [27]	75,4 % [27]	80,9 % [27]
Intelligence Index v4.0	50,0 [23]	Comparable [23]	Comparable [23]
Tâches GitHub Réelles	77,8 % [27]	75,4 % [27]	80,9 % [27]
Vending Bench 2 (Simulation)	$4 432 [27]	Non spécifié	$4 967 [27]

En plus de ses capacités textuelles, Zhipu AI a lancé GLM-5V-Turbo, un modèle multimodal spécialisé dans la transformation de maquettes UI en code frontend fonctionnel.[28] Avec un score de 94,8 sur le benchmark Design2Code, il surpasse nettement Claude Opus 4.6 (77,3) pour la génération de composants HTML/CSS à partir de captures d'écran ou de fichiers Figma.[28] Cette performance indique une parité, voire une supériorité, sur des segments de niche de la programmation, bien que GPT-5.4 conserve l'avantage sur l'automatisation globale de l'ordinateur.[28]

Cependant, l'utilisation des modèles Z.ai comporte des nuances. Bien que les performances en anglais et en chinois soient robustes, des artefacts de ponctuation chinoise peuvent parfois apparaître dans la sortie, et la vitesse de réponse en mode d'analyse profonde est environ 30 à 40 % plus lente que celle de Claude ou GPT.[27] De plus, les thématiques politiquement sensibles en Chine restent soumises à une censure rigoureuse, ce qui peut affecter certaines tâches de rédaction ou d'analyse contextuelle non techniques.[27]

Moonshot AI et Kimi K2.5 : L'Optimisation pour la Vitesse et le Frontend

Moonshot AI a introduit avec Kimi K2.5 un modèle open-source qui défie la lignée Codex sur le terrain de la réactivité et de la spécialisation frontend. Kimi K2.5 se distingue par une vitesse d'exécution stupéfiante de 334 tokens par seconde, soit quatre fois la vitesse de GPT-5.4 et sept fois celle de Claude Opus 4.6.[29] Cette rapidité est couplée à une excellente maîtrise des frameworks visuels, avec un score de 85,0 % sur LiveCodeBench et 76,8 % sur SWE-bench Verified.[21]

Tableau 5 : Tableau de Bord des Performances Kimi K2.5 (Mars 2026)

Domaine	Score Kimi K2.5	Vainqueur Propriétaire (GPT/Claude)	Écart
Code (SWE-bench)	76,8 % [29]	80,8 % (Opus 4.6) [29]	-4 pts
Raisonnement (HLE)	50,2 % [29]	41,6 % (GPT-5.4) [29]	+8,6 pts
Connaissances (MMLU)	87,1 % [29]	88,5 % (GPT-5.4) [29]	-1,4 pts

Vitesse (tok/s)	334 [29]	78 (GPT-5.4) [29]	4,3x plus rapide
Latence	0,31 s [29]	0,95 s (GPT-5.4) [29]	3x plus faible

L'avantage de Kimi réside dans sa capacité à maintenir une cohérence dans les dialogues longs grâce à une fenêtre de contexte de 256K tokens, particulièrement efficace pour les tâches de développement frontend où les interactions visuelles et les allers-retours sur le style sont fréquents.[5] Bien qu'il soit légèrement en retrait par rapport au GPT-5.4 sur la résolution de bugs complexes dans de grands dépôts (SWE-bench), sa supériorité en matière de raisonnement pur sur le benchmark Humanity's Last Exam (HLE) suggère une capacité de logique brute qui surpasse les modèles occidentaux de 8 à 10 points.[29]

Baidu ERNIE 5.0 et l'Intégration des Graphes de Connaissances

Baidu a lancé ERNIE 5.0, un système multimodal natif massif de 2,4 trillions de paramètres, optimisé pour les puces Kunlun de Baidu.[30] Contrairement aux modèles de la lignée Codex qui s'appuient principalement sur l'entraînement par les données textuelles, ERNIE 5.0 intègre profondément le vaste graphe de connaissances de Baidu.[30] Cette intégration améliore considérablement le rappel factuel et réduit les hallucinations, un point critique pour le développement de logiciels dans des domaines hautement réglementés ou complexes comme la finance ou la santé.[30]

ERNIE 5.0 se distingue par une performance exceptionnelle en mathématiques, où il se classe deuxième mondial dans l'Arena LMSYS, juste derrière GPT-5.2-High.[30] Pour les tâches de programmation, cette rigueur mathématique se traduit par une génération de code algorithmiquement plus précise.[30] La version ERNIE-4.5-VL-28B-A3B-Thinking, quant à elle, introduit des capacités de raisonnement visuel avancé, comme le zoom automatique pour l'extraction de texte dans les schémas techniques, positionnant Baidu comme un acteur de premier plan pour les ingénieurs travaillant sur des systèmes embarqués ou de l'analyse de plans industriels.[33]

Analyse Comparative des Architectures et Capacités de Raisonnement

La parité entre les IA chinoises et la lignée OpenAI Codex 5.3/5.4 n'est pas uniforme ; elle se fragmente selon les dimensions de coût, de vitesse, de contexte et d'autonomie. GPT-5.4 conserve une avance dans l'exécution de tâches au niveau de l'OS (Computer Use) et dans l'unification des modalités audio et vidéo, offrant une polyvalence inégalée pour les flux de travail qui nécessitent une interaction directe avec l'interface graphique.[1] Cependant, les modèles chinois ont pris l'avantage dans plusieurs domaines clés.

La Gestion du Contexte Long et de la Mémoire

Alors que GPT-5.4 supporte un million de tokens, sa performance de rappel chute drastiquement au-delà de 256K tokens (environ 21,4 % de précision sur certains tests de navigation dans les graphes).[1] À l'inverse, l'architecture Engram de DeepSeek V4 maintient une fidélité quasi-parfaite de 97 % à cette même échelle, faisant de lui l'outil supérieur pour l'analyse de dépôts de code complets sans perte de contexte.[4] Cette différence structurelle suggère que pour des projets de grande envergure (plus de 500 fichiers), le modèle chinois est techniquement plus fiable.[4]

Tableau 6 : Efficacité du Rappel Contextuel (Needle-in-a-Haystack)

Plage de Contexte	GPT-5.4	DeepSeek V4 (Engram)	Claude Opus 4.6
0 - 128K tokens	93,0 % [1]	> 99 % [4]	Très forte [4]
128K - 256K tokens	79,3 % [1]	> 98 % [4]	Inconnue [4]
256K - 1M tokens	21,4 % [1]	97,0 % [10]	Forte (Bêta) [4]

Économie et Déploiement Agentique

L'émergence du "Vibe Coding"—un mode de développement où l'IA gère l'essentiel de l'implémentation—dépend de la capacité à faire tourner des agents de manière intensive et peu coûteuse.[26] Dans ce paradigme, le prix du token devient le facteur limitant. Le fait que DeepSeek V4 ou MiniMax M2.5 soient 20 à 50 fois moins chers que GPT-5.4 change la nature même de l'assistance au codage : au lieu de demander une solution à l'IA, le développeur peut lui demander de générer des centaines de variantes, de les tester de manière croisée et de retenir la plus performante, un luxe inabordable avec les modèles d'OpenAI ou d'Anthropic.[4]

Intégration dans les IDE et Flux de Travail des Développeurs

La performance brute ne suffit pas ; l'intégration dans les outils quotidiens est cruciale pour la parité réelle. En 2026, l'écosystème s'est fragmenté entre les solutions propriétaires et les plateformes agnostiques.

- **Cursor et VS Code** : Bien qu'ils intègrent nativement GPT-5.4 et Claude Opus 4.6, ces éditeurs supportent désormais l'ajout de clés API tierces. L'utilisation combinée d'OpenCode avec DeepSeek V4 est devenue la recommandation pour l'efficience

économique, offrant 90 % des capacités de Claude Code à 10 % du coût.[9]

- **JetBrains AI Assistant** : Il conserve une intégration forte pour les entreprises, mais souffre de limitations dans la connaissance globale de la base de code par rapport aux agents comme Cursor ou aux modèles à long contexte comme Qwen3.[34]
- **Solutions Locales** : Qwen3-Coder-Next et GLM-5 sont devenus les standards pour les déploiements sur site (on-premises) via llama.cpp ou Ollama, garantissant la confidentialité du code source, un avantage stratégique sur la lignée Codex qui reste strictement basée sur le cloud.[15]

Tableau 7 : Classement des Outils de Développement par Performance Réelle (2026)

Rang	Outil / Modèle	Force Majeure	Point Faible
1	**Claude Code / Opus 4.6**	Raisonnement multi-fichiers [9]	Coût élevé [9]
2	**Cursor / GPT-5.4**	Expérience IDE native / Vitesse [9]	Propriétaire / Coût [9]
3	**OpenCode / DeepSeek V4**	Efficience économique extrême [9]	Configuration manuelle [9]
4	**GitHub Copilot**	Simplicité / Intégration écosystème [9]	Moins agentique [9]
5	**Kimi K2.5 / Local**	Confidentialité / Vitesse frontend [9]	Support multi-fichiers [9]

Vers une Intelligence de Programmation Décentralisée

L'analyse des signaux du marché montre que si GPT-5.4 reste le modèle le plus "intelligent" de manière holistique, capable de comprendre des instructions ambiguës et de naviguer dans des interfaces complexes, les modèles chinois ont atteint une parité fonctionnelle dans l'ingénierie logicielle quotidienne. L'innovation architecturale en Chine, stimulée par des contraintes géopolitiques, a produit des modèles plus efficients (DeepSeek V4), plus rapides (Kimi K2.5) et mieux adaptés au déploiement local (Qwen3).[4]

Le futur de l'assistance au codage semble se diriger vers un modèle hybride : utiliser des modèles comme GPT-5.4 ou Claude Opus 4.6 pour la planification architecturale et la

résolution de bugs critiques, tout en déléguant l'implémentation massive, les tests et la refactorisation de routine à des modèles comme DeepSeek V4 ou Qwen3. Cette "division du travail" entre les IA reflète un nouvel équilibre de puissance où les modèles chinois ne sont plus des imitateurs, mais des piliers indispensables de l'infrastructure technologique mondiale, offrant des capacités de parité avec la lignée Codex 5.4 tout en redéfinissant les standards d'efficience et d'accessibilité.[9]

Sources des citations

1. OpenAI GPT-5.4: Features, Benchmarks, Pricing & Computer Use (2026) - ALM Corp, consulté le avril 11, 2026, https://almcorp.com/blog/gpt-5-4/
2. GPT 5.4 Complete Guide 2026: Features, Pricing, Benchmarks & How to Use | NxCode, consulté le avril 11, 2026, https://www.nxcode.io/resources/news/gpt-5-4-complete-guide-features-pricing-models-2026
3. GPT-5.4 Review: Is It Worth Leaving GPT-5.3 Codex Behind? - Turing College, consulté le avril 11, 2026, https://www.turingcollege.com/blog/gpt-5-4-review-vs-gpt-5-3-codex
4. DeepSeek V4 vs Claude Opus 4.6 vs GPT-5.4: AI Coding Model Comparison (2026), consulté le avril 11, 2026, https://www.nxcode.io/resources/news/deepseek-v4-vs-claude-opus-vs-gpt-5-coding-2026
5. Best AI for Coding (2026): Every Model Ranked by Real Benchmarks, consulté le avril 11, 2026, https://www.morphllm.com/best-ai-model-for-coding
6. GPT-5.4: The Real Leap Isn't Coding | Blog - Alex Lavaee, consulté le avril 11, 2026, https://alexlavaee.me/blog/gpt-5-4-the-real-leap-isnt-coding/
7. SWE-bench Pro Benchmark 2026: 9 LLM scores | BenchLM.ai, consulté le avril 11, 2026, https://benchlm.ai/benchmarks/swePro
8. DeepSeek-V3 0324 vs gpt-5.3-codex — Pricing, Benchmarks & Performance Compared, consulté le avril 11, 2026, https://anotherwrapper.com/tools/llm-pricing/deepseek-v3-0324/gpt-53-codex
9. Best AI Coding Tools 2026: Complete Ranking by Real-World Performance | NxCode, consulté le avril 11, 2026, https://www.nxcode.io/resources/news/best-ai-for-coding-2026-complete-ranking
10. DeepSeek V4's 1-Trillion Parameter Architecture Targets | Introl Blog, consulté le avril 11, 2026, https://introl.com/blog/deepseek-v4-trillion-parameter-coding-model-february-2026
11. DeepSeek V4 (2026): 1T Parameters, 81% SWE-bench, $0.30/MTok — Full Specs | NxCode, consulté le avril 11, 2026, https://www.nxcode.io/resources/news/deepseek-v4-release-specs-benchmarks-2026
12. OSINT Report: DeepSeek V4 release timeline, internal training bottlenecks, and the shift from Huawei to NVIDIA. April 2026 Prediction. - Reddit, consulté le avril

11, 2026, https://www.reddit.com/r/DeepSeek/comments/1s694qu/osint_report_deepseek_v4_release_timeline/
13. DeepSeek V4 AI Model Launch Guide 2026: What You Need to Know - Vertu, consulté le avril 11, 2026, https://vertu.com/guides/deepseek-v4-complete-guide-2026/
14. Top Chinese AI Models in 2026: Capabilities, Use Cases, and Performance - ZenMux, consulté le avril 11, 2026, https://zenmux.ai/blog/top-chinese-ai-models-in-2026-capabilities-use-cases-and-performance
15. Qwen3-Coder-Next: The Complete 2026 Guide to Running Powerful ..., consulté le avril 11, 2026, https://dev.to/sienna/qwen3-coder-next-the-complete-2026-guide-to-running-powerful-ai-coding-agents-locally-1k95
16. Qwen3-Coder-Next Pushing Small Hybrid Models on Agentic Coding - Alibaba Cloud, consulté le avril 11, 2026, https://www.alibabacloud.com/blog/qwen3-coder-next-pushing-small-hybrid-models-on-agentic-coding_602864
17. Best LLM for Coding (March 2026): GPT-5.4 vs Claude 4.6 vs GLM-5 vs Kimi K2.5, consulté le avril 11, 2026, https://docs.kanaries.net/articles/best-llm-for-coding
18. Ultimate Guide - The Best Baidu Models in 2026 - SiliconFlow, consulté le avril 11, 2026, https://www.siliconflow.com/articles/en/the-best-baidu-models-in-2025
19. QwenLM/Qwen3: Qwen3 is the large language model ... - GitHub, consulté le avril 11, 2026, https://github.com/QwenLM/qwen3
20. DeepSeek V3.2 vs Llama 4 vs Qwen 3: Best Open-Source LLM for Production 2026, consulté le avril 11, 2026, https://www.spheron.network/blog/deepseek-vs-llama-4-vs-qwen3/
21. Best LLM for Coding 2026 | AI Coding Model Rankings & Benchmarks - Onyx, consulté le avril 11, 2026, https://onyx.app/best-llm-for-coding
22. Best AI Models April 2026: Claude Mythos Just Broke the Tier List, consulté le avril 11, 2026, https://mohitkhare.me/blog/ai-models-compared-april-2026/
23. GLM-5: from Vibe Coding to Agentic Engineering - arXiv, consulté le avril 11, 2026, https://arxiv.org/html/2602.15763v1
24. zai-org/GLM-5 - From Vibe Coding to Agentic Engineering - GitHub, consulté le avril 11, 2026, https://github.com/zai-org/GLM-5
25. GLM-5.1: Towards Long-Horizon Tasks - Z.ai, consulté le avril 11, 2026, https://z.ai/blog/glm-5.1
26. Which is the best for coding, Codex GPT-5.4 vs Claude Opus 4.6 vs DeepSeek-V3.2 vs Qwen3-Coder ? : r/vibecoding - Reddit, consulté le avril 11, 2026, https://www.reddit.com/r/vibecoding/comments/1si7ein/which_is_the_best_for_coding_codex_gpt54_vs/
27. GLM-5 by Z.ai in 2026: The Chinese Model That Pretends to Be Claude | mysummit.school, consulté le avril 11, 2026, https://mysummit.school/blog/en/glm5-zai-review-2026/

28. GLM-5V-Turbo: What Developers Should Know in 2026 | WaveSpeedAI Blog, consulté le avril 11, 2026, https://wavespeed.ai/blog/posts/glm-5v-turbo-developers-2026/
29. Open-source models are production-ready — here's the data (5 models × 5 benchmarks vs Claude Opus 4.6 and GPT-5.4) : r/LocalLLaMA - Reddit, consulté le avril 11, 2026, https://www.reddit.com/r/LocalLLaMA/comments/1ry4r56/opensource_models_are_productionready_heres_the/
30. Ernie 5.0 Tops LMSYS Arena: Baidu's Chinese Giant Outshines GPT ..., consulté le avril 11, 2026, https://medium.com/data-science-in-your-pocket/ernie-5-0-tops-lmsys-arena-baidus-chinese-giant-outshines-gpt-5-1-in-global-ai-battle-2ebd42217edd
31. Baidu's ERNIE 5 AI Model Rises Up the Rankings—A Math Wiz That Beats OpenAI's GPT 5.1 - Decrypt, consulté le avril 11, 2026, https://decrypt.co/354772/baidu-ernie-5-ai-model-rises-rankings-math-wiz-beats-gpt
32. Which Chinese AI Model Should You Choose? DeepSeek vs. Qwen vs. Baidu - Explyt, consulté le avril 11, 2026, https://explyt.ai/en/blog/best-chinese-llm
33. Baidu's ERNIE-4.5-VL-28B-A3B-Thinking Marks a Significant Step in Open Multimodal AI, consulté le avril 11, 2026, https://www.rockbirdmedia.com/post/baidu-ernie-multimodal-ai-benchmarks
34. Best AI IDEs in China of 2026 - Reviews & Comparison - SourceForge, consulté le avril 11, 2026, https://sourceforge.net/software/ai-ides/china/
35. DeepSeek V4 vs Claude Opus 4.6 vs GPT-5.4: What You Can Actually Compare in April 2026 | LaoZhang AI Blog, consulté le avril 11, 2026, https://blog.laozhang.ai/en/posts/deepseek-v4-vs-claude-opus-4-6-vs-gpt-5-4-verified-comparison
36. Best AI Code Editors 2026 (I Tested 10+) | Playcode Blog, consulté le avril 11, 2026, https://playcode.io/blog/best-ai-code-editors-2026
37. JetBrains AI vs Gemini Code Assist (2026): IDE-Native vs GCP, consulté le avril 11, 2026, https://www.augmentcode.com/tools/jetbrains-ai-vs-gemini-code-assist